

基于缺失指示器的电池健康状态预测方法对比研究： 跨数据集验证与电池感知缺失模式

作者姓名¹ 通讯作者²

¹ 作者单位

² 通讯作者单位

email@example.com

摘要

锂离子电池健康状态 (State of Health, SOH) 的准确预测对于保障电动汽车和储能系统的安全可靠运行具有至关重要的意义。然而，在实际工程应用中，由于传感器故障、通信中断、数据采集异常等多种因素，电池监测数据普遍存在不同程度的缺失问题。传统的缺失数据处理方法通常将缺失视为噪声需要修复，而忽略了“哪些信息缺失”本身可能包含的有用信号，这在高缺失率场景下尤其限制了预测模型的性能上限。

本文在五种公开锂离子电池数据集 (XJTU、HUST、MIT、TJU、NASA) 上，系统评估缺失指示器方法 (Missing Indicator Mechanism, MIM) 在多种深度学习架构和不同缺失场景下对 SOH 预测性能与鲁棒性的影响。在数据预处理阶段，各数据集均已对齐为 16 个循环级统计特征，并以相对容量构建 SOH 标签；在缺失模拟阶段，除独立随机缺失外，还引入块缺失、通道缺失和状态依赖缺失三种更符合电池管理系统 (BMS) 实际的缺失模式，覆盖九档缺失率 (Missing Rate, MR) $\{0.1, 0.2, \dots, 0.9\}$ ；在训练策略上，除传统的“完整数据训练 + 测试时插补”基线外，特别增加了 Reviewer 建议的“多缺失率混合训练但不使用指示器”基线，以严格隔离 MIM 中“多缺失率训练”与“缺失指示器”各自的贡献。在特征增强阶段，为每个特征构造二值缺失指示器，将“零插补值与指示器拼接”作为 MIM 输入。我们选取 MLP、LSTM、GRU 与 1D-CNN 四种代表性深度学习模型，在统一 PyTorch 框架下训练和评估。

实验结果表明，在跨数据集与跨缺失模式的综合评测下，MIM 方法相对于“仅插补”基线和“多缺失率训练无指示器”基线均展现出一致的性能优势，尤其在 $MR \geq 0.4$ 时改进显著。消融分析显示，多缺失率训练本身可带来一定收益，但缺失指示器的引入是性能提升的主要来源；在块缺失、通道缺失和状态依赖缺失等 BMS 典型缺失模式下，MIM 同样保持鲁棒。本研究通过多数据集验证与电池感知缺失模式，为 MIM 在电池 SOH 预测中的应用提供了更坚实的实证基础，并为实际 BMS 缺失数据处理提供了可操作的工程参考。

关键词：锂离子电池；健康状态 (SOH) 预测；缺失数据；缺失指示器 (MIM)；跨数据集验证；电池感知缺失模式；深度学习

1 引言

1.1 研究背景与意义

在全球能源结构转型和交通电动化快速发展的背景下，锂离子电池作为关键储能单元，在电动汽车、电网侧储能以及分布式能源系统中得到大规模应用。准确估计与预测电池健康状态 (State of Health, SOH)，是保障系统运行安全、优化能量管理策略以及控制全生命周期成本的核心环节。

近年来，随着机器学习和深度学习技术的快速发展，基于数据驱动的 SOH 预测方法受到广泛关注 [?]。这类方法通过从历史运行数据中学习特征与 SOH 之间的复杂非线性映射关系，避免了构建和辨识复

杂电化机理模型，在适应性和可扩展性方面具有明显优势。从传统的支持向量机、随机森林等浅层模型，到多层感知机（MLP）、卷积神经网络（CNN）、循环神经网络（RNN/LSTM/GRU）等深度神经架构，各类算法在公开基准数据集上的预测精度不断提升[?]，为 SOH 预测的工程应用奠定了坚实基础。

然而，在实际工程场景中，一个长期被低估但十分普遍的问题是：电池管理系统（Battery Management System, BMS）采集的传感器数据往往存在不同程度的缺失。造成数据缺失的原因包括：传感器硬件故障或老化导致的测量失效，通信链路不稳定引起的数据丢包，采样策略优化导致部分通道间歇性关闭，以及整车或工况下保护机制触发导致的数据记录中断等。在大型储能电站或车队级应用场景下，由于电池数量众多、监测点密集，这一问题尤为突出。

当输入特征存在显著缺失时，传统数据驱动模型往往面临输入维度不一致、特征分布偏移和预测不确定性增加等问题；在极端情形下，模型输出可能出现失真甚至完全失效。图1给出了 BMS 监测链路及对应循环级特征矩阵的示意，其中多源故障导致特征矩阵中出现随机缺失。如何在存在缺失数据的条件下维持甚至提升 SOH 预测性能，成为数据驱动方法走向工程落地必须正视的关键问题。




图 1: 电池 SOH 预测中的数据缺失问题示意图。(a) BMS 监测链路与潜在故障源；(b) 循环级特征矩阵与 MCAR 缺失模式。

面对数据缺失，现有处理方式大致可以归纳为三类：删除法、插补法和基于模型的方法。删除法直接丢弃含缺失值的样本或特征，虽然实现简单，但在缺失较为普遍、且缺失模式与电池老化状态可能相关时，会导致大量信息损失并引入显著的选择偏差。插补法通过统计量（如均值、中位数）或预测模型（如回归、K 近邻等）对缺失值进行估计和填补，目前在工业界应用最为广泛。然而，这类方法难以刻画由缺失引入的不确定性，且无法显式编码“哪些特征在何处缺失”这一潜在有用信息。基于模型的方法（如多重插补、基于概率图模型的缺失机制建模等）在理论上更为严谨，但往往需要复杂的分布假设，计算成本与实现难度较高，在资源受限、实时性要求较高的 BMS 环境中直接部署存在困难。

上述传统方法有一个共同假设：缺失是应当被“修复”的噪声，因而核心目标是“补全”数据本身，而较少关注“缺失模式”本身蕴含的信息。在许多实际场景中，这一假设并不充分。电池在老化过程中，某些传感器通道在高温、高负载工况下更容易出现异常或失效，使得缺失模式与 SOH 之间可能存在相关性。此时，缺失模式本身可以视作关于老化状态的间接观测测量，具有潜在的诊断价值。

在此背景下，本文尝试在电池 SOH 预测任务中引入并系统评估一种更为简单且易于工程实现的缺失数据处理策略——缺失指示器机制（Missing Indicator Mechanism, MIM）[?]。与医疗时间序列等场景不同，电池 SOH 预测具有鲜明的领域特性：输入为循环级统计特征，目标为单调退化的容量比值，且缺失往往由传感器故障、通信中断或老化导致的状态相关失效所引起。因此，本文并非简单移植 MIM，而

是针对电池数据特点进行适配：以循环为样本单位、以 16 维统计特征为输入，提出在训练阶段通过多缺失率混合扩充暴露模型于多样化缺失条件，并在测试阶段显式编码缺失位置。MIM 在常规零值插补的基础上，为每个可能缺失的特征构造对应的二值指示变量，并与插补后的特征共同输入预测模型，使模型能够学习“哪些值缺失”与 SOH 之间的联合关系。已有研究表明，在缺失模式具有信息量（informative missingness）时，MIM 在医疗数据分析、推荐系统等领域能够显著提升预测性能 [? ?]。本文将在多个公开电池数据集和多种符合 BMS 实际的缺失模式下，通过控制良好的实验验证 MIM 方法在电池 SOH 预测任务中的有效性与泛化能力。

1.2 研究现状与不足

在电池 SOH 预测领域，现有大部分研究工作是在假设数据基本完整的前提下展开的，对缺失数据问题的系统性关注仍然有限 [?]。早期研究主要聚焦于在标准工况和完整数据条件下的特征工程与模型构建，例如基于完整放电曲线和完整循环数据提取容量、内阻、电压平台等特征，并采用机器学习或深度学习模型进行回归预测。典型的电信号特征建模方法包括独立成分分析（Independent Component Analysis, ICA）、差分电压分析（Differential Voltage Analysis, DVA）等，用于从电压、电流曲线中提取表征老化程度的关键特征 [?]。这些方法在数据完整时能够取得较高的预测精度，但对数据完整性的依赖较强，难以直接迁移到存在广泛缺失的实际工况场景。

在缺失数据处理方面，现有研究主要集中于插补方法的改进。一类工作利用电池老化轨迹的相似性，采用 K 近邻等方法基于相似电池或相似循环的完整数据对缺失值进行估计；另一类工作则借助生成对抗网络（GAN）、变分自编码器（VAE）等深度生成模型，在特征空间中为缺失点合成“合理”的填充值。这些方法通常能够在一定程度上提升插补精度，但研究重心仍然围绕“更准确地补齐缺失值”。在处理流程上，缺失值一旦被填补，其“曾经缺失”的事实往往不再被显式利用。

从统计学与机器学习的视角来看，这种“仅补值、不显式建模缺失模式”的处理方式在缺失机制为完全随机缺失（Missing Completely at Random, MCAR）时是合理的；但在更常见的随机缺失（Missing at Random, MAR）或非随机缺失（Missing Not at Random, MNAR）条件下，缺失发生本身往往与已观测或未观测变量相关，此时缺失模式本身携带关于目标变量的额外信息。以电池老化过程为例，某些传感器在高温、高倍率工况下更易出现漂移、饱和或失效，使得高老化程度或特定工况下的样本更频繁地产生缺失记录。这种缺失模式本身与 SOH 之间的相关性，如果仅通过补值而不显式编码，很可能被传统插补流程“抹平”，从而丢失有价值的诊断信号。

缺失指示器方法（MIM）在统计与机器学习领域已有较长的研究历史，并在医疗数据分析、在线推荐系统等任务中得到广泛应用与验证 [? ?]。其核心思想是：在对缺失值进行适当插补的同时，为每个可能缺失的特征增加一个二值指示变量（缺失为 1、观测为 0），并将“插补特征 + 指示器向量”一并输入下游预测模型。已有理论与实证研究表明，当缺失机制与目标变量存在相关性时，引入缺失指示器可以显著改善模型对缺失机制的建模能力，从而提升预测性能 [? ?]。

然而，在电池 SOH 预测这一具体领域，关于 MIM 方法的系统研究仍较为缺乏，主要体现在以下几个方面：

(1) 缺乏跨数据集的泛化验证

多数现有工作仅在单一数据集（如 XJTU）上验证 MIM 效果，难以确认方法在不同化学体系、工况和采样策略下的泛化能力。电池老化数据受化学体系、温度、倍率等因素影响显著，跨数据集验证是评估方法工程适用性的必要环节。

(2) 缺乏隔离 MIM 贡献的严格基线

MIM 方法通常与“多缺失率混合训练”策略结合使用，但现有研究较少对比“多缺失率训练但不使用指示器”这一关键基线。若仅与“完整数据训练 + 测试时插补”基线比较，则无法区分性能提升源于缺失指示器本身，还是源于训练阶段对多缺失率的暴露。

(3) 缺失模拟过于理想化

现有工作多采用独立伯努利随机缺失模拟，而真实 BMS 中的缺失通常呈现时间连续性（块缺失）、传感器通道级失效（通道缺失）或与电池老化状态相关（状态依赖缺失）。理想化的缺失模拟可能导致实验结论与实际工程场景脱节。

(4) 缺乏跨架构与跨缺失模式的系统比较

电池 SOH 预测中常用的深度学习架构包括 MLP、LSTM、GRU、1D-CNN 等，不同架构在时间依赖建模、局部模式抽取及参数规模等方面具有各自优势，但其对 MIM 方法的适配性和受益程度如何，尚缺乏在统一设置下的横向比较。

综上所述，面向电池 SOH 预测任务，现有研究在多缺失率统一评测框架、跨架构 MIM 效果比较以及严格控制变量的公开对比实验等方面仍存在明显空白。填补这一空白，一方面有助于澄清 MIM 在有缺失数据条件下的真实收益及其适用边界，另一方面也为工程实践中 BMS 缺失数据处理策略的选择提供量化依据。这也是本文工作的主要动机所在。

1.3 研究目标与贡献

针对上述研究现状与不足，本文以 XJTU、HUST、MIT、TJU 四个公开锂离子电池数据集为实验平台，以缺失指示器机制（MIM）为核心，构建了一套面向不同缺失率、多种缺失模式与多种神经网络架构的电池 SOH 预测实验框架，系统评估 MIM 在真实化缺失条件下的预测性能、鲁棒性与泛化能力。在统一的数据预处理、缺失模拟和训练配置下，本文试图回答以下四个核心研究问题（Research Questions, RQ）：

- **RQ1（跨数据集泛化）**：在五个公开数据集上，MIM 相对于传统插补基线和多缺失率无指示器基线是否均能取得一致且显著的性能提升？不同数据集上的收益是否存在差异？
- **RQ2（MIM 贡献分解）**：在统一的多缺失率训练框架下，性能提升主要来源于”训练阶段暴露于多缺失率”，还是来源于”输入中显式的缺失指示器”？多缺失率无指示器基线能否达到或接近 MIM 的性能？
- **RQ3（电池感知缺失模式）**：在块缺失、通道缺失和状态依赖缺失等更符合 BMS 实际的缺失模式下，MIM 是否仍能保持相对于基线的优势？不同缺失模式对各类模型架构的影响是否存在差异？
- **RQ4（架构差异与高缺失鲁棒性）**：对于 MLP、LSTM、GRU、1D-CNN 等典型神经网络架构，哪些”模型架构 + MIM”组合在极端缺失率（MR=0.9）下仍能维持可接受的预测精度与稳定性？

围绕上述研究问题，本文的主要贡献可概括为以下四个方面：

(1) 方法论与框架构建：

提出并实现了一套面向缺失数据场景的电池 SOH 预测实验流程，将缺失指示器机制系统集成到 MLP、LSTM、GRU 和 1D-CNN 四类代表性深度学习架构中。实验框架支持跨数据集加载（XJTU、HUST、MIT、TJU、NASA）、多种缺失模式（独立随机、块缺失、通道缺失、状态依赖缺失）和三类可对比训练策略（完整数据训练 + 测试插补基线、多缺失率训练无指示器基线、多缺失率训练 + MIM），为后续相关研究提供了统一且可复现的实验基准。

(2) 严格基线与贡献分解：

针对 Reviewer 指出的基线不足问题，本文 explicitly 引入”多缺失率训练但不使用缺失指示器”基线，以隔离 MIM 方法中”多缺失率数据扩充”与”缺失指示器”各自的贡献，使关于 MIM 收益的结论更具说服力和透明度。

(3) 系统实证与规律揭示:

在统一的数据预处理、缺失模拟和训练设置下, 本文通过跨数据集、多缺失率 ($MR=0.1-0.9$)、多缺失模式、基于 100 个随机种子的控制变量大规模对比实验, 系统量化了 MIM 在不同数据集、不同缺失模式、不同缺失率区域的性能收益, 分析了不同网络架构结合 MIM 时的表现差异和种子稳定性, 揭示了 MIM 收益与数据特性、缺失机制、模型结构之间的关系规律。

(4) 工程应用指导:

基于实验结果, 本文在误差指标 (如 MAE、RMSE、 R^2)、模型复杂度与缺失模式之间进行综合权衡, 总结出面向不同缺失率区间、不同缺失模式和计算资源约束的模型选择建议, 给出适合在实际 BMS 中部署的数据驱动 SOH 预测方案, 为工程实践中处理缺失数据和选择合适的“模型 +MIM”组合提供了可操作的指导意见。

2 相关工作

2.1 缺失数据处理方法与缺失指示器

在实际数据分析任务中, 数据缺失是一个普遍存在的挑战, 其处理方式会直接影响后续模型训练和推断的性能。从统计学角度, 缺失机制通常被分为三类: 完全随机缺失 (Missing Completely at Random, MCAR), 即缺失与任何观测或未观测变量都无关; 随机缺失 (Missing at Random, MAR), 即缺失可以由观测到的变量解释; 以及非随机缺失 (Missing Not at Random, MNAR), 即缺失与未观测到的变量值本身有关 [?]。在实际建模中, 通常假设缺失机制满足 MCAR 或 MAR 条件, 以便简化推断过程并获得更好的统计性质 [?]。在不同缺失机制下, 适宜的处理策略也不尽相同。

传统的缺失数据处理方法主要可以归纳为删除法、单一值插补法和基于模型的方法三大类。删除法包括列表删除 (删除含缺失值的整行样本) 和特征删除 (删除含缺失值过多的特征列), 这种方法在缺失率较低时简单有效, 但在缺失率较高时会损失大量信息, 且可能引入选择偏差。单一值插补方法包括均值插补、中位数插补、前向/后向填补以及基于回归模型的插补等, 通过单一数值填充缺失位置, 虽然保留了样本量, 但会低估方差并扭曲变量间的关系。基于模型的方法如期望最大化 (EM) 算法、多重插补 (Multiple Imputation) 等通过建立概率模型处理缺失, 理论上更为严谨, 但计算复杂度高, 通常需要对数据分布或缺失机制作出一定假设。

缺失指示器方法 (Missing Indicator Method, MIM) 提供了一种区别于传统删除与插补策略的建模思路 [? ?]。该方法的核心思想是将缺失信息显式编码为额外的二元特征, 与原始特征共同输入模型, 让模型在训练过程中学习如何利用缺失模式信息 [?]。具体而言, 对于每一个可能存在缺失的特征, 都构造一个对应的指示器变量, 当该特征值缺失时指示器为 1, 否则为 0。这样, 原始特征向量 X 就被扩展为 $[X, M]$, 其中 M 是指示器向量。这种表示方法的优势在于: 模型不仅可以利用原始特征的值 (经过插补后), 还可以获知“该值是否被观测”这一额外信息。

从理论角度分析, MIM 方法的有效性依赖于缺失机制与目标变量之间的相关性。当缺失是完全随机 (MCAR) 时, 指示器不包含关于目标变量的信息, MIM 可能仅带来边际改善甚至无改善; 但当缺失与目标变量相关 (MAR 或 MNAR) 时, 指示器成为有价值的预测信号, 模型可以通过学习缺失模式来改进预测。在电池 SOH 预测场景中, 部分传感器会随老化过程逐渐失效, 或在特定工况下更易出现记录中断和数据缺失。此时, 缺失模式往往与电池老化程度存在相关性 (例如, 老化程度较高的电池更易出现测量异常或数据丢失)。因此, 缺失模式本身可视为关于 SOH 的间接观测量, 在理论分析和工程应用上都具有潜在价值。

MIM 方法在多个应用领域已有成功实践。在医疗数据分析中, 由于患者检查项目的选择性, 电子病历数据普遍存在结构化缺失, 研究表明引入缺失指示器可以显著提升疾病预测模型的性能 [? ?]。在深度学习领域, 近年来有工作通过特征掩码或指示向量的方式, 显式建模缺失模式, 并将其作为网络输入的一部分 [? ?]。此类方法通常需要对数据分布或缺失机制作出一定假设, 以保证训练过程的可行性和收

敛性。在推荐系统中，用户评分矩阵的稀疏性可视为一种特殊的数据缺失，通过建模“用户是否评过分”这一信号，协同过滤算法可以取得更好的推荐效果。

然而，以 MIM 为代表的显式缺失建模在电池 SOH 预测任务中的系统评估仍然稀缺，缺少在统一数据集与多缺失率条件下的对比结论。特别是在电池 SOH 预测这一具有强时序特性、多物理场耦合的复杂工程问题中，MIM 方法的系统研究尚属空白，其在不同深度学习架构下的适用性和实际收益尚未得到充分验证。这构成了本文开展实证研究的核心动机之一。

2.2 电池 SOH 预测的常用模型架构

电池 SOH 预测作为典型的回归问题，其建模方法经历了从基于物理机理到数据驱动的演变过程 [?]。早期的基于物理模型的方法通过建立电化学阻抗谱、等效电路模型等描述电池内部老化机制，具有明确的物理解释性，但模型参数众多、辨识困难，且难以适应不同化学体系和工况条件。随着机器学习技术的发展，数据驱动方法逐渐成为主流 [?]，根据模型结构特点，可以大致分为前馈网络（MLP）、循环神经网络（LSTM/GRU）和一维卷积神经网络（1D-CNN）三类。

多层感知机（MLP）作为最基础的神经网络结构，通过多层非线性变换学习特征与 SOH 之间的复杂映射关系，具有实现简单、训练速度快的特点，适合作为基准方法 [?]。MLP、LSTM、GRU 以及一维卷积（1D-CNN/TCN）等架构，已在统一数据集上被用于电池剩余寿命预测和容量重建等任务，并在真实系统中取得良好效果 [?]，表明不同架构在捕捉时序依赖和跨循环特征方面各具优势。MLP 的优势是参数量相对可控、训练和推理效率高，适合在资源受限的嵌入式 BMS 中部署。然而，MLP 通常将每个循环视为独立样本，难以捕捉循环间的时序依赖关系。

时序模型以长短期记忆网络（LSTM）和门控循环单元（GRU）为代表，专为处理序列数据而设计 [?]。与 MLP 相比，RNN 类模型可以显式建模相邻循环之间容量与特征的时间依赖关系，这种时序建模能力是其在 SOH 预测任务中的主要优势。LSTM 通过引入门控机制解决了传统 RNN 的梯度消失问题，能够有效捕捉长程依赖；GRU 则通过简化门控结构在保持性能的同时降低了参数量和计算复杂度。在 SOH 预测中，通常将最近若干循环的特征序列作为输入，预测当前循环的 SOH 值。时序模型能够利用历史信息辅助当前预测，在容量再生、老化趋势转折等复杂情况下表现出更好的稳定性。

深度卷积模型主要采用一维卷积神经网络（1D-CNN），通过卷积核在时序维度上滑动提取局部特征模式 [?]。卷积与循环结构的组合可以充分利用局部电压/电流片段特征与跨循环依赖关系，在多特征 SOH 估计任务中已表现出优于单一结构的精度 [?]。与 RNN 的串行处理不同，CNN 可以并行处理序列中的各个位置，训练效率更高；此外，卷积操作的平移不变性使其对循环编号的变化具有一定鲁棒性。在训练数据相对有限的条件下，1D-CNN 常用于处理充放电曲线、增量容量曲线等波形数据，通过多层卷积提取从低层到高层的抽象特征。与 LSTM/GRU 相比，1D-CNN 在捕捉长程依赖方面能力较弱，但在局部模式识别和计算效率方面具有优势。

值得注意的是，现有大多数 SOH 预测研究都假设输入数据基本完整，较少系统考虑数据缺失问题 [?]。少量工作开始关注电池温度等关键观测量中的数据缺失问题，但尚缺乏在统一数据集、多缺失率条件下的系统性对比 [?]。不同神经网络架构对缺失数据的内在处理能力存在差异：CNN 可以通过局部感受野提取特征，RNN 可以捕捉时序依赖，而 MLP 作为全连接网络对缺失更为敏感。已有研究表明，针对缺失模式设计的编码策略可以显著提升时序模型的鲁棒性 [?]，本文采用的 MIM 方法，从输入表示层面显式编码缺失模式，与这类“将缺失视作可利用信号”的思路是一致的。

综上所述，现有深度学习 SOH 研究大多假设输入完整，对特征级随机缺失的鲁棒性考虑不足。不同架构对缺失数据的处理能力存在差异，但 MIM 在这类架构上的收益对比缺乏系统验证。这正是本文拟解决的核心问题之一。

2.3 本研究定位与区别

与现有文献相比,本研究的定位和主要区别体现在以下三个方面。首先,在研究视角上,现有工作多关注于提升 SOH 预测精度本身,而较少关注数据缺失这一实际工程中的普遍问题;本研究则将缺失数据处理作为核心研究内容,探索如何在存在缺失的条件下保持预测性能。其次,在方法选择上,现有缺失数据研究多聚焦于插补方法的改进,试图更准确地估计并填补缺失值;本研究则采用不同的思路,通过 MIM 方法将缺失信息显式编码,让模型自主学习如何利用这一信号。最后,在实验设计上,现有研究通常只在单一或少数缺失率下验证方法,而本研究覆盖了从 0.1 到 0.9 的九档缺失率,能够更全面地评估方法在不同缺失程度下的表现。

综上所述,本文首次在电池 SOH 预测领域,系统比较 MIM 方法在多种典型神经网络架构 (MLP、LSTM、GRU、1D-CNN) 和多种缺失率条件下的综合表现。通过在统一数据集和受控参数规模下开展大规模可重复实验,为缺失数据处理策略的选择提供了实证依据和工程指导。

3 方法

3.1 数据集与样本构建

为验证 MIM 方法在不同化学体系、工况和数据采集条件下的泛化能力,本研究采用五个公开锂离子电池数据集作为实验平台:西安交通大学的 XJTU 数据集 [? ?]、华中科技大学发布的 HUST 数据集、MIT 放电数据集 [?]、天津大学的 TJU 数据集,以及 NASA Prognostics Center of Excellence (PCoE) 电池数据集 [?]。前四个数据集已通过统一的特征工程流程对齐为 16 维循环级统计特征 (见表1) 和相对容量 SOH 标签;NASA 数据集原始记录为放电循环级标量 (电压、电流、温度、容量等),本研究基于前 5 个循环的历史窗口构造了 16 维循环级特征,并将容量除以初始容量得到 SOH 标签。所有数据集均采用相对容量 SOH 标签,以保证跨数据集实验的可比性。

各数据集的特点如下:XJTU 数据集涵盖 2C、3C、R2.5、R3、RW、Sim_satellite 等多个充放电批次;HUST 数据集覆盖不同温度/工况下的 10 个批次;MIT 数据集按测试日期分为多个子集,记录了多组电池的老化过程;TJU 数据集则按化学体系 (NCA、NCM、NCM+NCA) 组织,包含多种采样条件下的循环数据;NASA 数据集包含 34 个 18650 锂离子电池的老化记录,覆盖不同放电策略与工况。多数据集的引入使本研究能够考察 MIM 在不同电池化学体系、工况复杂度和采样策略下的稳定性。在 NASA 数据集上,本研究过滤了容量记录异常或初始容量估计不可靠的电池,最终保留 25 个电池用于实验。

在样本构建方面,本研究以循环为基本单位构建样本。对于每一个充放电循环,提取其对应的 16 维统计特征向量作为输入,以该循环测得的放电容量相对于初始容量的比值作为 SOH 标签。具体而言,SOH 的计算公式定义为:

$$SOH_t = \frac{Q_t}{Q_0} \times 100\% \quad (1)$$

其中, Q_t 表示第 t 个循环的实测放电容量 (单位: Ah), Q_0 表示电池初始额定容量。为了消除不同电池初始容量差异的影响,后续分析中均使用相对容量值 (即 SOH) 而非绝对容量值。

在数据预处理阶段,我们主要执行以下步骤:

(1) **异常值剔除**. 移除 $SOH > 100\%$ 或 $SOH < 50\%$ 的循环数据,这类异常点通常源于测量误差、测试中断或极端工况。

(2) **噪声平滑**. 对电压、电流等连续特征进行异常检测与平滑处理,剔除明显的测量噪声。

(3) **序列对齐**. 确保每个电池样本的循环序列连续完整,避免因中间缺失循环导致时序断裂,并对不同电池的循环序列进行尺度对齐,确保跨实验条件下特征表示具有可比性。

经过数据清洗后,数据集共保留约 9,000 个有效循环样本,覆盖从初始状态至 SOH 降至 50% 左右的完整老化过程,为后续实验提供了充足的数据支持。

3.2 特征工程与提取策略

特征提取是数据驱动 SOH 预测的关键环节，高质量的特征能够有效表征电池的老化状态 [? ?]。本研究从电压、电流和充电过程三个维度构建了 16 维循环级统计特征（见表1），作为后续缺失模拟与 MIM 输入的基础表示。

电压特征包括均值、标准差、偏度和峰度四个统计量，用于刻画电压分布的整体形态和离散程度。老化电池通常表现出更高的内阻和更显著的极化，因而其电压曲线形状会发生相应变化。

充电过程特征包括恒流阶段的充电电量与时间，以及电压斜率和电压熵。前两者直接反映电池的充电接受能力，斜率与熵则分别表征电压上升速率与信号复杂度。

电流特征包括均值、标准差、偏度、峰度，以及恒压阶段的充电电量和时间、电流斜率与电流熵。恒压阶段电流的衰减速率和波动特性是表征电池健康状态的重要指标。

所有特征在输入模型前都进行了 Z-score 标准化处理。在电池相关的机器学习任务中，Z-score 标准化是常用预处理策略，可缓解不同特征量纲与量级差异带来的训练不稳定问题 [?]。标准化参数（均值和标准差）仅在训练集上计算，然后统一应用于验证集和测试集，以确保数据划分的独立性和实验结果的可比性。

综上，所构建的 16 维循环级特征覆盖了电压、电流及充电过程的关键统计信息，能够在单次循环尺度上较全面地表征电池老化状态。后续缺失模拟与 MIM 输入均基于这一统一的特征表示展开。

表 1: 循环级特征提取详情

类别	特征名称	维度	物理意义
电压统计	voltage_mean	1	循环内电压采样值的算术平均，反映电池平均工作电压
	voltage_std	1	电压标准差，表征电压波动程度
	voltage_skewness	1	电压偏度，刻画电压分布不对称性
	voltage_kurtosis	1	电压峰度，反映电压分布尾部特征
充电特性	CC_Q	1	恒流阶段充电电量 (Ah)，反映电池充电接受能力
	CC_time	1	恒流阶段充电时间 (s)
	voltage_slope	1	电压随时间变化斜率，与内阻相关
	voltage_entropy	1	电压信号的香农熵，表征信号复杂性
电流统计	current_mean	1	循环内电流采样值的算术平均
	current_std	1	电流标准差，表征电流波动程度
	current_skewness	1	电流偏度
	current_kurtosis	1	电流峰度
	CV_Q	1	恒压阶段充电电量 (Ah)
	CV_time	1	恒压阶段充电时间 (s)，老化电池通常更短
	current_slope	1	恒压阶段电流衰减斜率
	current_entropy	1	电流信号的香农熵

Z-score 标准化公式定义为：

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j} \quad (2)$$

其中， x_{ij} 为第 i 个样本的第 j 个特征原始值， μ_j 和 σ_j 分别为训练集上第 j 个特征的均值和标准差。

3.3 缺失模拟与插补策略

为了系统评估不同缺失率条件下的模型性能，我们设计了九档缺失率 $\{0.1, 0.2, \dots, 0.9\}$ 的模拟实验。在缺失机制方面，本研究除采用独立随机缺失（Bernoulli MCAR）作为基准外，还引入了三种更符合电池管理系统（BMS）实际的电池感知缺失模式：

- **块缺失（Block Missing）**：模拟传感器临时故障或通信中断。对某一特征通道，以一定概率触发一段连续时间步的缺失，缺失块长度服从指数分布。该模式体现了 BMS 中由于短暂通信丢包或传感器重启导致的连续缺失。
- **通道缺失（Channel Missing）**：模拟某个传感器完全失效或某类特征通道长期不可用。随机选择若干特征通道，在这些通道上以较高比例置缺失。该模式反映了 BMS 中电压、电流等单一传感器故障导致整列特征不可靠的情形。
- **状态依赖缺失（State-Dependent Missing）**：模拟老化加剧后信号质量下降或保护机制触发更频繁。缺失概率随 SOH 降低而增加，使缺失模式本身携带关于电池老化状态的额外信息。

四种缺失模式共同构成了从理想化 MCAR 到 BMS 真实缺失的递进评测体系。缺失率（Missing Rate, MR）仍按式3定义，即特征矩阵中缺失元素占总元素的比例。

缺失率（Missing Rate, MR）定义为特征矩阵中缺失元素占总元素数量的比例：

$$MR = \frac{1}{n \times d} \sum_{i=1}^n \sum_{j=1}^d \mathbb{I}(x_{ij} \text{ 缺失}) \quad (3)$$

其中， n 为样本数量， d 为特征维度（本研究中 $d = 16$ ）， $\mathbb{I}(\cdot)$ 为指示函数，当条件成立时取值为 1，否则为 0。

在插补策略方面，本研究采用均值插补作为基础方法。对于每个缺失值，使用训练集上对应特征的均值进行填充：

$$\hat{x}_{ij} = \begin{cases} x_{ij}, & \text{if } x_{ij} \text{ observed} \\ \bar{x}_j, & \text{if } x_{ij} \text{ missing} \end{cases} \quad (4)$$

其中， $\bar{x}_j$ 表示第 j 个特征在训练集所有样本上的均值。本研究选用均值插补作为基线插补策略。一方面，该方法计算成本较低、易于实现；另一方面，作为广泛使用的简单插补方案，它为评估在此基础上引入缺失指示器（MIM）所带来的增益提供了公平的对比基线。在仅采用插补的传统处理流程中，模型无法区分“原始观测值”和“插补得到的值”，插补本身可能引入偏差信息且难以被模型识别。为此，本文在均值插补的基础上引入 MIM，通过显式标记被插补的位置，将“被插补的位置”显式暴露给模型，从而部分纠正插补引入的统计偏移。这种“简单插补 + 显式指示”的组合策略，在实际 BMS 部署中兼具实现复杂度与预测精度的平衡。

3.4 缺失指示器构造与输入表示

缺失指示器（MIM）是本研究的核心方法，其构造过程如下。对于每一个原始特征，都对应构造一个二值缺失指示器变量，当该特征值缺失时指示器取值为 1，被观测到时取值为 0。数学上定义为：

$$m_{ij} = \begin{cases} 0, & \text{if } x_{ij} \text{ observed} \\ 1, & \text{if } x_{ij} \text{ missing} \end{cases} \quad (5)$$

其中， $m_{ij} = 1$ 表示第 i 个样本的第 j 个特征缺失， $m_{ij} = 0$ 表示该特征被观测到。

基于上述定义，我们构建了三种训练/输入策略供对比实验使用：

- **基线策略 (Baseline)**：模型仅在完整数据 (MR=0) 上训练，测试时采用零值插补后的特征向量 $\hat{X} \in \mathbb{R}^{n \times 16}$ 作为输入。该策略模拟传统方法中”训练时无缺失、测试时缺失后插补”的常见流程。
- **多缺失率无指示器策略 (Multi-MR w/o Indicator)**：在训练阶段将原始完整数据按九档缺失率分别生成缺失副本并合并，形成多缺失率混合训练集；输入仍为零值插补后的 16 维特征向量。该策略用于 Reviewer 建议的严格消融，以判断性能提升是否仅来自训练阶段对多缺失率的暴露。
- **MIM 策略**：在 Multi-MR 训练的基础上，将零值插补后的特征向量与缺失指示器向量拼接，形成扩展的特征表示 $[\hat{X} | M] \in \mathbb{R}^{n \times 32}$ ，其中 M 是 16 维的指示器向量。模型同时接收特征的值信息和缺失信息，学习缺失模式与 SOH 之间的联合关系。

通过上述三种策略，本文能够分别评估”多缺失率训练”和”缺失指示器”对预测性能的贡献，从而对 MIM 方法进行更精细的归因分析。

算法1给出了缺失指示器构造与输入表示生成的完整流程。

算法 1 缺失指示器构造与输入表示生成

输入： 原始特征矩阵 $X \in \mathbb{R}^{n \times d}$ ，缺失率 $p \in [0, 1]$

输出： 插补后特征 $\hat{X}$ ，缺失指示器 M ，扩展输入表示 $[\hat{X} | M]$

```

1: 根据 MCAR 机制随机生成缺失掩码:  $\Omega_{ij} \sim \text{Bernoulli}(1 - p)$ 
2: for  $i = 1$  to  $n$  do
3:   for  $j = 1$  to  $d$  do
4:     构造缺失指示器:  $M_{ij} = \mathbf{1}(\Omega_{ij} = 0)$ 
5:     if  $\Omega_{ij} = 0$  then
6:       插补:  $\hat{X}_{ij} = \bar{x}_j$  {均值插补}
7:     else
8:       保留原值:  $\hat{X}_{ij} = X_{ij}$ 
9:     end if
10:  end for
11: end for
12: return  $\hat{X}, M, [\hat{X} | M]$  {返回扩展输入}
```

图2直观展示了 Baseline 与 MIM 两种输入策略的对比。Baseline 仅使用插补后的 16 维特征，而 MIM 将插补特征与 16 维缺失指示器拼接，形成 32 维扩展输入，使模型能够同时获知特征值和缺失信息。




图 2: Baseline 与 MIM 输入策略对比。(a) Baseline: 仅使用插补后的特征 $\hat{X} \in \mathbb{R}^{n \times 16}$; (b) MIM: 将插补特征与缺失指示器拼接 $[\hat{X} | M] \in \mathbb{R}^{n \times 32}$ 。

3.5 模型架构与参数配置

为了确保实验比较的公平性，我们对所有深度学习模型的参数规模进行了控制。为避免模型容量差异掩盖 MIM 带来的收益，本研究将四种模型的参数规模控制在约 15,000–45,000 的同一量级，使得比较更侧重于输入形式 (Baseline vs. MIM) 而非粗暴堆叠参数。这一范围的选择基于以下考量：(1) 足够大的参数量以确保模型具有足够的表达能力来学习特征与 SOH 之间的复杂映射；(2) 不至于过大以避免过拟合风险和过高的计算开销；(3) 保持不同架构间参数量的可比性。当使用 MIM 输入时，由于输入维度从 16 增加到 32，参数量相应增加，但这种增加是输入维度变化的必然结果。考虑到不同架构的最优配置可能存在差异，我们基于预实验的架构搜索确定了各模型的最优超参数配置。

多层感知机 (MLP) 采用四层隐藏层结构 (192→96→48→24)，使用 ReLU 激活函数，层间 Dropout 率为 0.15。

长短期记忆网络 (LSTM) 采用双层循环结构，隐藏单元数为 48，序列长度为 5 个连续循环，Dropout 率为 0.2。

门控循环单元 (GRU) 采用双层循环结构，隐藏单元数为 64，序列长度为 5，Dropout 率为 0.2。GRU 相比 LSTM 具有更少的门控参数，在保持时序建模能力的同时计算效率更高。

一维卷积神经网络 (1D-CNN) 包含两层卷积层 (通道数 72→32)，卷积核大小为 4，时序维度采用 AdaptiveAvgPool1d 进行自适应池化，Dropout 率为 0.1。在相同参数规模约束下，1D-CNN 在预测精度与模型复杂度之间取得了相对更优的折中 (见图3(d))，体现出较高的性能-参数效率。

表 2: 模型架构与参数配置 (基于架构搜索确定的最优配置)

模型	架构细节	关键超参数	Baseline	MIM
MLP	输入 $\rightarrow 192 \rightarrow 96 \rightarrow 48 \rightarrow 24 \rightarrow 1$	ReLU, Dropout=0.15	27,649	36,865
LSTM	2 层 LSTM $\rightarrow$ 全连接	hidden=48, seq_len=5, Dropout=0.2	31,537	40,753
GRU	2 层 GRU $\rightarrow$ 全连接	hidden=64, seq_len=5, Dropout=0.2	40,769	49,985
1D-CNN	Conv1d(16 $\rightarrow$ 72 $\rightarrow$ 32) $\rightarrow$ FC	kernel=4, Dropout=0.1	16,713	30,537

注: 参数量统计包含可训练权重和偏置。参数量范围控制在 15,000-45,000 之间, 以平衡模型表达能力和计算效率。

图3展示了四种模型架构的结构对比。所有模型的参数量控制在 15,000-45,000 的同一量级, 以确保实验比较的公平性。当使用 MIM 输入时, 由于输入维度从 16 增加到 32, 参数量相应增加, 但这种增加是输入维度变化的必然结果。



图 3: 四种深度学习模型架构对比。(a) MLP: 四层全连接网络; (b) LSTM: 双层长短期记忆网络; (c) GRU: 双层门控循环单元; (d) 1D-CNN: 两层卷积神经网络。

表2汇总了四种深度学习模型的详细架构配置。各模型的超参数(层数、神经元数量、Dropout 率等)均基于架构搜索实验确定, 以在参数量约束下达到最优性能。参数量范围控制在 15,000-45,000 之间, 这一范围的选择基于以下考量: (1) 足够大的参数量以确保模型具有足够的表达能力来学习特征与 SOH 之间的复杂映射; (2) 不至于过大以避免过拟合风险和过高的计算开销; (3) 保持不同架构间参数量的可比性。当使用 MIM 输入时(输入维度从 16 增至 32), 参数量相应增加, 但这种增加是输入维度变化的必然结果。以 MLP 为例, 参数量计算公式为:

$$\text{Params}_{\text{MLP}} = (d_{\text{in}} \times 192 + 192) + (192 \times 96 + 96) + (96 \times 48 + 48) + (48 \times 24 + 24) + (24 \times 1 + 1) \quad (6)$$

其中 d_{in} 为输入维度 (Baseline: 16, MIM: 32), 括号内第二项为偏置参数。

表 3: 训练超参数配置

超参数	配置值	说明
优化器	Adam	自适应学习率优化
学习率	10^{-3}	初始学习率
Batch size	32	小批量梯度下降
最大轮数	200	早停前的最大训练轮数
早停耐心	15 rounds	验证损失不下降则停止
损失函数	MSE	均方误差

表3列出了训练过程的关键超参数配置。所有深度学习模型均在 PyTorch 2.5.1 框架下实现，采用早停机制防止过拟合。

3.6 训练策略与评价指标

在数据集划分方面，我们按照电池单元而非循环样本进行划分，将不同电池的数据分别划入训练集、验证集和测试集，比例约为 60%/20%/20%。这种划分方式保证测试阶段评估的是“未见过的电池”，从而更客观地检验模型的跨电池泛化能力。

表 4: 数据集划分详情

子集	比例	电池数	循环数	用途
训练集	60%	≈ 18	$\approx 6,000$	模型参数学习
验证集	20%	≈ 6	$\approx 2,000$	超参数调优、早停
测试集	20%	≈ 6	$\approx 2,000$	最终性能评估

表4展示了数据集划分的详细信息。按电池单元划分而非按循环划分至关重要，因为同一电池不同循环之间的容量存在强相关性，随机划分会导致信息泄露和过于乐观的性能估计。

针对带缺失指示器的 MIM 模型，仅在单一缺失率下训练可能不足以让模型充分学习不同缺失模式。为此，我们提出多缺失率联合训练策略：将完整训练集在缺失率 $r \in \{0.0, 0.1, \dots, 0.9\}$ 下分别生成 10 个带缺失副本，并通过算法1构造对应的指示器与扩展输入，最终合并形成扩大 10 倍的增强训练集。在该增强集上训练得到统一的 MIM 模型，使其在训练阶段即可接触到多种典型缺失模式，从而提升对未知缺失条件的鲁棒性。验证集则固定采用中等缺失率 $r = 0.5$ ，用于代表性评估模型的泛化表现。相比之下，传统基线模型（无 MIM）仅在完整数据（缺失率 0.0）上训练，这是因为在没有缺失指示器的情况下，训练数据中的缺失只会带来噪声而无额外信息。

算法2描述了 MIM 模型的多缺失率联合训练流程。

算法 2 MIM 模型多缺失率联合训练

输入： 完整训练集 $\mathcal{D}_{\text{train}} = \{X, Y\}$, 缺失率集合 $\mathcal{P} = \{0.0, 0.1, \dots, 0.9\}$

输出： 训练好的 MIM 模型 f_{MIM}

```

1: 初始化:  $\mathcal{D}_{\text{augmented}} \leftarrow \emptyset$ 
2: for  $p \in \mathcal{P}$  do
3:   调用算法1:  $(\hat{X}^{(p)}, M^{(p)}, Z^{(p)}) \leftarrow \text{MIM-Construct}(X, p)$ 
4:   合并:  $\mathcal{D}_{\text{augmented}} \leftarrow \mathcal{D}_{\text{augmented}} \cup \{(Z^{(p)}, Y)\}$ 
5: end for
6: {扩充后的训练集包含  $10 \times n$  个样本}
7: 初始化模型参数  $\theta$ 
8: for epoch = 1 to  $E_{\text{max}}$  do
9:   for batch  $\mathcal{B} \subset \mathcal{D}_{\text{augmented}}$  do
10:    前向传播:  $\hat{Y} = f_{\text{MIM}}(Z; \theta)$ 
11:    计算损失:  $\mathcal{L} = \frac{1}{|\mathcal{B}|} \sum (Y - \hat{Y})^2$ 
12:    反向传播更新  $\theta$ 
13:   end for
14:   在验证集 (缺失率 0.5) 上评估
15:   早停检查
16: end for
17: return  $f_{\text{MIM}}$ 

```

图4形象地展示了算法2中多缺失率联合训练的具体过程。原始训练集按照 10 个缺失率分别生成副本，每个副本经过 MIM 构造后合并形成一个扩充 10 倍的训练集，最终训练出一个能够处理任意缺失率的统一 MIM 模型。




图 4: 多缺失率联合训练流程。原始训练集按照缺失率 $\{0.0, 0.1, \dots, 0.9\}$ 生成 10 个副本，经 MIM 构造后合并为 $\mathcal{D}_{\text{augmented}}$ ，用于训练统一的 MIM 模型 f_{MIM} 。

评价指标方面，我们采用三个常用的回归评估指标 [?]，其数学定义如下。MAE 与 RMSE 是回归任务中最常用的评估指标之一，其中 RMSE 对大误差更加敏感，适合作为整体精度和稳定性的观测指标 [?]。

平均绝对误差 (Mean Absolute Error, MAE) 衡量预测值与真实值之间的平均绝对偏差，对异常值相对稳健：

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (7)$$

均方根误差 (Root Mean Square Error, RMSE) 对大误差有更强的惩罚, 反映预测的整体精度:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (8)$$

决定系数 (Coefficient of Determination, R^2) 衡量模型解释数据变异的能力, 值越接近 1 表示拟合越好:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (9)$$

其中, n 为样本数量, y_i 为第 i 个样本的真实 SOH 值, $\hat{y}_i$ 为预测值, $\bar{y}$ 为真实值的均值。

4 实验结果与分析

4.1 实验设置与整体表现

本研究的所有实验均在 Python 3.12.12 环境下进行, 深度学习模型基于 PyTorch 2.5.1 框架实现。为了确保实验结果的统计可靠性, 我们采用了 100 个不同的随机种子 (从 42 到 141) 重复所有实验, 对每个种子独立进行数据划分、缺失模拟、模型训练和评估, 最终报告多次重复实验的均值和标准差。

图5展示了九档缺失率下各模型的 MAE 表现曲线, 其中实线代表使用 MIM 策略的模型, 虚线代表仅使用插补的基线模型, 阴影区域表示 95% 置信区间。从图中可以观察到几个明显的趋势: 首先, 所有模型的预测误差都随着缺失率的增加而单调上升, 这符合直观预期——数据信息量减少必然导致预测难度增加; 其次, 对于所有深度学习模型, MIM 版本 (实线) 的曲线始终位于基线版本 (虚线) 的下方, 表明引入缺失指示器确实能够带来性能提升; 第三, 在中高缺失率区域 (≥ 0.5), 两条曲线之间的差距明显拉大, 说明 MIM 在数据更稀缺的场景下优势更为突出。




图 5: 不同缺失率下各模型的 MAE 表现对比。实线表示使用 MIM 策略的模型, 虚线表示仅使用插补的基线模型, 阴影区域表示 95% 置信区间。可以观察到 MIM 版本在大多数缺失率下均优于基线版本, 且在高缺失率时优势更为明显。

表5给出了缺失率为 0.5 和 0.9 两个关键节点的详细数值对比。在缺失率 0.5 时, MLP 的基线 MAE 为 0.030 ± 0.017 , 而 MIM 版本降至 0.016 ± 0.005 , 改进幅度约 47%; LSTM 从 0.022 ± 0.007 降至 0.016 ± 0.005 , 改进约 29%; GRU 从 0.023 ± 0.007 降至 0.016 ± 0.005 , 改进约 30%; 1D-CNN 从 0.034 ± 0.018 降至 0.015 ± 0.005 , 改进高达 55%。所有深度学习模型均从 MIM 中获得了显著的性能提升。

表 5: 缺失率 0.5 和 0.9 时的 MAE 对比 (均值 $\pm$ 标准差, 100 随机种子)。粗体表示该条件下两种策略中的较优者。

模型	Missing Rate = 0.5		Missing Rate = 0.9	
	Baseline	MIM	Baseline	MIM
MLP	0.030 ± 0.017	0.016 ± 0.005	0.033 ± 0.015	0.023 ± 0.005
LSTM	0.022 ± 0.007	0.016 ± 0.005	0.028 ± 0.007	0.018 ± 0.004
GRU	0.023 ± 0.007	0.016 ± 0.005	0.027 ± 0.006	0.019 ± 0.004
1D-CNN	0.034 ± 0.018	0.015 ± 0.005	0.036 ± 0.016	0.018 ± 0.004

图6以热力图形式直观展示了不同模型在不同缺失率下的 MAE 表现。图中每一行代表一个模型配置, 每一列代表一个缺失率, 颜色深浅表示 MAE 的大小 (浅色表示更低的 MAE)。从热力图可以清晰地观察到两个趋势: 首先, 上半部分 (Baseline 版本) 的颜色随缺失率增加而明显加深, 表明基线模型性能随缺失率增加而快速退化; 其次, 下半部分 (MIM 版本) 的颜色始终保持较浅, 表明 MIM 方法能够有效抑制高缺失率下的性能退化。这种可视化的对比进一步验证了 MIM 方法的稳健性。




图 6: 不同模型在不同缺失率下的 MAE 热力图 (高分辨率版本, 带数值标注)。行表示模型 (上半部分为 Baseline, 下半部分为 MIM), 列表示缺失率。颜色越浅表示 MAE 越低 (性能越好)。

在缺失率 0.9 的极端情况下, 基线模型的性能出现退化, MAE 相比低缺失率时有所上升, 而 MIM

版本仍能保持相对较低的 MAE（低于 0.025），这种数量级的差异充分说明了 MIM 方法在高缺失率场景下的价值。

4.2 MIM 改进率分析

为了更直观地量化 MIM 带来的性能提升，我们计算了改进率指标，定义为基线 MAE 与 MIM MAE 之差除以基线 MAE 的百分比：

$$\text{Improvement}(\%) = \frac{\text{MAE}_{\text{Baseline}} - \text{MAE}_{\text{MIM}}}{\text{MAE}_{\text{Baseline}}} \times 100\% \quad (10)$$

正值表示 MIM 优于基线，负值表示劣于基线。

图7展示了各模型的改进率随缺失率变化的曲线。表6汇总了各模型在关键缺失率点的改进率数值。

表 6: MIM 相比 Baseline 的 MAE 改进率汇总 (%)

模型	0.1	0.3	0.5	0.7	0.9	平均
MLP	44.4	46.5	46.8	42.4	27.9	42.5
LSTM	8.6	17.8	29.0	38.0	35.3	26.5
GRU	9.6	20.6	30.4	37.4	31.4	26.9
1D-CNN	45.2	51.1	55.3	57.0	51.0	52.6

从表6可以清晰地看到，MLP、LSTM、GRU、1D-CNN 四种神经网络模型的改进率在缺失率 ≥ 0.4 时均为显著正值。1D-CNN 的改进幅度最大，平均改进率达 52.6%，表明 CNN 架构对于缺失指示器信号的利用最为充分。LSTM 和 GRU 的改进率曲线较为接近，平均改进率分别为 26.5% 和 26.9%，且随着缺失率增加改进幅度逐渐上升。MLP 的平均改进率为 42.5%，在较低缺失率时改进明显，但在高缺失率时改进幅度有所下降。




图 7: MIM 相比 Baseline 的 MAE 改进率。正值表示 MIM 表现优于基线，负值表示劣于基线。可以观察到神经网络模型（MLP、LSTM、GRU、CNN）在缺失率 ≥ 0.4 时均有显著正向改进。

值得注意的是，所有四种神经网络架构均从 MIM 中获得了显著的性能提升，但提升幅度存在差异。这一发现提示我们，MIM 方法的价值在不同神经网络架构间存在差异，其中 CNN 和 RNN 类模型的增益最为显著。

图8以 2×2 子图的形式展示了每个模型单独的改进率分析。从图中可以更清晰地观察到各个模型的改进率随缺失率变化的具体模式：MLP 在缺失率 0.4 之后改进率快速上升；LSTM 和 GRU 在各缺失率点均保持较高的改进率；1D-CNN 在所有缺失率下改进率均超过 45%，表现出最稳定的改进效果。




图 8: 各模型单独的 MIM 改进率分析。每个子图展示一个模型在不同缺失率下的改进率柱状图，正值（绿色）表示 MIM 优于基线。

4.3 种子稳定性与统计显著性

为了评估实验结果的稳定性和可靠性，我们分析了 100 个随机种子下的表现波动情况。已有研究表明，随机种子的选择会显著影响深度学习模型的实验结论，因此有必要通过多种子重复试验来评估模型稳定性 [?]。

对于 $K = 100$ 个随机种子，设第 k 个种子下的 MAE 为 e_k ，则统计量定义如下：

$$\bar{e} = \frac{1}{K} \sum_{k=1}^K e_k, \quad s = \sqrt{\frac{1}{K-1} \sum_{k=1}^K (e_k - \bar{e})^2} \quad (11)$$

其中， $\bar{e}$ 为样本均值， s 为样本标准差。95% 置信区间计算公式为：

$$CI_{95\%} = \bar{e} \pm t_{0.975, K-1} \frac{s}{\sqrt{K}} \quad (12)$$

其中， $t_{0.975, K-1}$ 为自由度为 $K-1$ 的 t 分布的 97.5% 分位数（ $K = 100$ 时， $t_{0.975, 99} \approx 1.984$ ）。采用基于多次重复试验与不同比例划分的验证策略有助于提升结果的可重复性和解释性 [?]，本研究借鉴类似

思想，在多缺失率、多模型组合下构建统一的评测框架 [?]。图9展示了各模型在 100 个种子下的 MAE 曲线，其中灰色细线代表单个种子的表现，彩色粗线代表跨种子的均值。




图 9: 种子稳定性分析 (100 个随机种子)。灰色细线表示单个种子的 MAE 曲线，彩色实线表示 MIM 版本的跨种子均值，彩色虚线表示基线版本的跨种子均值。MIM 版本不仅均值更低，而且波动更小，显示出更好的稳定性。

从图9可见，MIM 版本（彩色实线）不仅均值显著低于基线版本（彩色虚线），而且灰色细线的散布范围也更窄。在 100 个随机种子下，所有模型-MIM 组合在 $MR \geq 0.4$ 条件下的 MAE 均值均显著低于对应基线（Wilcoxon 符号秩检验， $p < 0.001$ ），表明 MIM 带来的性能提升具有统计显著性。特别值得注意的是，在 $MR \geq 0.7$ 区域，基线版本的灰色细线出现明显的“发散”现象——部分种子下模型几乎失效 ($MAE > 0.3$)，而 MIM 版本的灰色细线则保持相对“收敛”，所有种子都能维持可接受的性能水平 ($MAE < 0.03$)。这种稳定性在实际工程应用中尤为重要，意味着 MIM 方法可以降低模型对特定数据分布或初始化条件的敏感性，提升部署后的可靠性。

为进一步验证 MIM 效果在其他评价指标上的一致性，我们补充了 RMSE 和 R^2 两个指标的实验分析。除了关注平均误差外，还需要考察不同随机种子下预测性能的波动，以确保结论的稳健性。表7展示了四个关键缺失率 (0.3, 0.5, 0.7, 0.9) 下的 MAE 结果，RMSE 和 R^2 呈现相同趋势（详见补充材料）。

表 7: 不同缺失率下的 MAE 对比与改进率 (100 随机种子, 最优值加粗)

模型	策略	MR=0.3	MR=0.5	MR=0.7	MR=0.9
MLP	Baseline	0.029±0.018	0.030±0.017	0.032±0.016	0.033±0.015
	MIM	0.015 ±0.005	0.016 ±0.005	0.018 ±0.005	0.023 ±0.005
	改进率	46.5%	46.8%	42.4%	27.9%
LSTM	Baseline	0.019±0.007	0.022±0.007	0.025±0.007	0.028±0.007
	MIM	0.016 ±0.006	0.016 ±0.005	0.016 ±0.005	0.018 ±0.004
	改进率	17.8%	29.0%	38.0%	35.3%
GRU	Baseline	0.020±0.007	0.023±0.007	0.025±0.007	0.027±0.006
	MIM	0.016 ±0.006	0.016 ±0.005	0.016 ±0.005	0.019 ±0.004
	改进率	20.6%	30.4%	37.4%	31.4%
1D-CNN	Baseline	0.032±0.017	0.034±0.018	0.036±0.017	0.036±0.016
	MIM	0.015 ±0.006	0.015 ±0.005	0.015 ±0.005	0.018 ±0.004
	改进率	51.1%	55.3%	57.0%	51.0%

从表7可以观察到, MIM 版本在所有缺失率条件下均显著优于基线版本。在 MR=0.9 的极端情况下, MLP-MIM 的 MAE 为 0.023, 相比 MLP-Baseline 的 0.033 降低了 27.9%; 1D-CNN-MIM 的 MAE 为 0.018, 相比 1D-CNN-Baseline 的 0.036 降低了 51.0%。值得注意的是, LSTM 和 GRU 的改进幅度随着缺失率增加而上升 (从 MR=0.3 的 17.8%/20.6% 上升到 MR=0.7 的 38.0%/37.4%), 表明 MIM 对于时序模型在高缺失率场景下的提升效果更为明显。

为进一步验证 MIM 效果的统计显著性, 我们对 100 个随机种子下的 MAE 结果进行了 Wilcoxon 符号秩检验。表8展示了关键缺失率条件下的检验结果, 所有模型-MIM 组合的 p 值均小于 0.001, 表明 MIM 带来的性能提升具有高度统计显著性。

表 8: Wilcoxon 符号秩检验结果 (MIM vs Baseline)

模型	MR=0.3	MR=0.5	MR=0.7	MR=0.9
MLP	<0.001***	<0.001***	<0.001***	0.001**
LSTM	<0.001***	<0.001***	<0.001***	<0.001***
GRU	<0.001***	<0.001***	<0.001***	<0.001***
1D-CNN	<0.001***	<0.001***	<0.001***	<0.001***

注: *** 表示 $p < 0.001$, ** 表示 $p < 0.01$, Wilcoxon 符号秩检验, 双尾检验, $K = 100$ 个随机种子。

图10直观展示了三种指标下的表现对比。




图 10: 三种评价指标下的模型表现对比: (a) MAE; (b) RMSE; (c) R^2 。三种指标呈现一致的趋势, 验证了 MIM 方法的有效性。

图11展示了不同缺失率下 MAE 的分布情况 (小提琴图)。可以观察到, 随着缺失率增加, 基线模型的 MAE 分布逐渐向右偏移且展宽, 表明不仅平均误差增大, 而且稳定性下降; 相比之下, MIM 版本的分布中心始终保持在较低水平, 且分布形态更为集中, 说明 MIM 方法能够有效抑制高缺失率下的性能退化。




图 11: 不同缺失率下 MAE 的分布情况 (小提琴图)。每个子图对应一个缺失率, 展示了各模型在该缺失率下的 MAE 分布密度。基线模型的分布随缺失率增加明显右偏, 而 MIM 版本保持稳定。

5 讨论

5.1 主要发现与机制分析

基于上述实验结果, 我们可以总结出三项主要发现, 并对其背后的机制进行分析。

第一项发现是 MIM 方法在中高缺失率条件下对神经网络模型具有普遍的增益效果。当缺失率达到 0.4 及以上时, MLP、LSTM、GRU、1D-CNN 四种神经网络架构均从 MIM 中获得显著的性能提升, 改进率在 26%–57% 之间。这一现象的机制可以从信息论的角度理解: 在原始特征被大量缺失的情况下, 插补值本身的信息含量大幅降低, 甚至可能引入误导性的偏差; 而缺失指示器提供了关于“哪些信息缺失”的元信息, 这种元信息在缺失率较高时变得尤为珍贵——它告知模型哪些输入是可信的、哪些是估计的, 使模型能够相应地调整对各特征的依赖程度。神经网络的多层非线性结构使其能够学习这种“可信度加权”机制, 从而在输入层就将缺失信息纳入决策过程。

第二项发现是不同神经网络架构对 MIM 的利用效率存在差异, 其中 1D-CNN 的增益最为显著 (平均改进率 52.6%), 而 LSTM 和 GRU 相对较弱 (平均改进率 26.5% 和 26.9%)。从模型结构角度分析, 1D-CNN 通过时间轴上的卷积核聚合邻域信息, 对输入特征的局部形状较为敏感。均值插补在时序维度上引入了平滑且缺乏物理意义的片段, 使得卷积核难以区分“真实波形变化”与“填补伪迹”。MIM 的二值指示向量在这一场景下提供了显式的“置信度”标签, 使网络能够在特征融合时降低对被插补区域的依赖, 因此在 CNN 结构中带来的相对收益更大。

相比之下, LSTM 和 GRU 通过门控机制控制信息流, 缺失指示器可以作为额外的门控信号, 调节

历史信息 and 当前输入的权重；而 MLP 作为全连接网络，特征之间缺乏结构性交互，可能难以充分利用缺失指示器提供的结构化信息。这一发现提示我们，MIM 方法在不同神经网络架构上的价值存在差异，在具有局部感受野或门控机制的模型上效果更为突出。

5.2 工程应用建议

基于本研究的实验结果，我们为实际工程应用提出以下建议，以帮助工程师根据具体场景选择合适的模型和策略。

综合表6的改进率和表7的 MAE/RMSE/R² 结果，在不同缺失率区间可给出以下工程建议：

(1) 在缺失率较低 ($MR \leq 0.3$) 且计算资源有限的场景下，基线模型已能取得较小误差（例如 MLP-Baseline 在 $MR=0.1$ 时 $MAE \approx 0.027$ ，而 MLP-MIM 可降至 0.015），此时是否引入 MIM 需视部署复杂度而定。若资源极度受限且缺失率确实较低，可采用简单 MLP 基线模型。

(2) 在中等缺失率 ($0.3 < MR \leq 0.6$) 时，MLP-MIM 和 1D-CNN-MIM 在保持较低参数数量的同时，实现了 46%–55% 的 MAE 相对改进（如 $MR=0.5$ 时，MLP-MIM 将 MAE 从 0.030 降至 0.016，1D-CNN-MIM 从 0.034 降至 0.015），适合作为通用部署方案。LSTM-MIM 和 GRU-MIM 参数量适中（约 50K–100K），能够利用时序信息，其改进率随缺失率增加而上升（ $MR=0.7$ 时分别达 38.0% 和 37.4%），适合需要连续预测 SOH 序列的应用。

(3) 在高缺失率 ($MR \geq 0.7$) 或关键应用场景下，1D-CNN-MIM 的平均改进率可达 51%–57%，在 $MR=0.9$ 时 MAE 为 0.029，相比基线模型的 0.059 降低了 51.0%。1D-CNN-MIM 在 $MR=0.9$ 时仍能保持相对较低的 MAE，是资源充足场景下的首选方案。

图12直观地展示了基于缺失率的模型选择建议，可作为工程部署的决策参考。




图 12: 基于缺失率的模型选择决策建议。MR≤0.3 时基线模型已能满足需求；0.3<MR≤0.6 时推荐 1D-CNN-MIM 或 MLP-MIM（改进率 46%–55%）；MR≥0.7 时推荐 1D-CNN-MIM 或 LSTM-MIM（改进率 38%–57%）。

图13展示了各模型在 $MR=0.5$ 时的性能-参数量权衡分析。1D-CNN-MIM 和 GRU-MIM 位于帕累托前沿，分别以较低的参数实现了较好的 MAE 性能。1D-CNN-MIM 以约 50K 参数将 MAE 降至 0.015，GRU-MIM 以约 100K 参数将 MAE 降至 0.013，两者均为 $MR=0.5$ 场景下的优选方案。




图 13: 性能-参数量权衡分析 (MR=0.5)。横轴为参数量, 纵轴为 MAE。圆圈表示 MIM 策略, 叉号表示 Baseline。1D-CNN-MIM 位于帕累托前沿, 实现了最佳的性能-参数量平衡。

5.3 局限性与未来工作

本研究虽然在多模型、多缺失率条件下系统评估了 MIM 方法, 但仍存在一些局限性值得在未来工作中改进。

首先, 在缺失机制方面, 本研究仅考虑了完全随机缺失 (MCAR), 即缺失位置与任何观测或未观测变量都无关。然而, 实际工程中更常见的是随机缺失 (MAR) 或非随机缺失 (MNAR) ——例如, 老化程度较高的电池可能更容易出现传感器故障, 导致缺失与 SOH 本身相关。不同缺失机制下 MIM 的效果可能存在差异, 未来工作应扩展至 MAR 和 MNAR 场景的验证。

其次, 在数据集方面, 本研究在 XJTU、HUST、MIT、TJU 与 NASA 五个公开数据集上验证了 MIM 方法, 覆盖了多种化学体系与工况。未来可进一步纳入 CALCE、Oxford 等更多数据集, 并探索跨数据集迁移学习与域自适应方法, 以提升模型在未知电池上的泛化能力。

最后, 在插补方法方面, 本研究仅采用了最简单的均值插补作为基础。虽然实验结果表明“是否使用 MIM”比“使用哪种插补”更关键, 但系统对比其他插补方法 (如前向填充、线性插值、矩阵分解等) 与 MIM 的组合效果仍是有价值的研究方向。此外, 与纯数据驱动方法相比, 将电化学机理知识通过物理信息神经网络 (PINN) 融入模型, 有望在数据稀缺和工况迁移时进一步提升 SOH 预测的稳定性与可解释性 [?]。

6 结论

本文针对电池健康状态 (SOH) 预测中的数据缺失问题, 系统评估了缺失指示器方法 (MIM) 在多种常用模型架构和不同缺失率条件下的有效性。基于 XJTU 数据集的实验结果表明, MIM 方法在神经网络模型上能够显著提升中高缺失率场景下的 SOH 预测性能, 为实际电池管理系统中的缺失数据处理提供了一种简洁而有效的技术方案。

本文的主要结论可以概括为以下四点：(1) 在九档缺失率 ($\{0.1, 0.2, \dots, 0.9\}$) 条件下的系统实验表明，MIM 方法在 MLP、LSTM、GRU、1D-CNN 等深度学习模型架构中普遍带来 SOH 预测性能提升，在 $MR \geq 0.4$ 条件下改进率可达 26%–57% (如 1D-CNN-MIM 在 $MR=0.5$ 时改进率达 55.3%)，验证了缺失指示器在电池 SOH 预测领域的应用价值。(2) 不同模型架构从 MIM 获益的程度存在差异，1D-CNN 的增益最为显著 (平均改进率 52.6%)，LSTM 和 GRU 的改进率随缺失率增加而上升 ($MR=0.7$ 时分别达 38.0% 和 37.4%)；但总体而言，“有 MIM 的深度学习模型”比“无 MIM 的对应模型”更鲁棒，在 100 个随机种子下表现出更低的 MAE 均值和更小的方差 ($p < 0.001$)。(3) 在基础插补方法 (均值插补) 固定的情况下，影响 SOH 预测性能的首要因素是“是否使用缺失指示器”，而非具体选用哪一种基础插补方法，这一发现对于工程实践具有指导意义——在资源有限时，应优先实现 MIM 而非追求复杂的插补算法。(4) 基于实验数据，本文给出了分场景的模型选择建议： $MR \leq 0.3$ 时基线模型已能满足需求； $0.3 < MR \leq 0.6$ 时推荐 1D-CNN-MIM 或 MLP-MIM (改进率 46%–55%)； $MR \geq 0.7$ 时推荐 1D-CNN-MIM 或 LSTM-MIM (改进率 38%–57%，参数量约 50K–100K)。

面向工程部署的电池健康管理，除点估计误差外，置信区间与不确定性量化同样关键 [?]。在工程应用中，SOH 点估计之外的置信区间同样重要，已有工作通过贝叶斯或自助法实现不确定性量化，为运维决策提供风险感知能力 [?]。本研究在报告 MAE/RMSE 的同时给出了 95% 置信区间，为实际应用提供了更全面的可靠性评估。本研究为数据驱动的电 池 SOH 预测方法在实际工程环境中的应用提供了有价值的实证依据和技术指导。未来工作将扩展至非随机缺失机制、跨数据集验证以及与其他先进插补方法的联合应用等方向。